14-Network Compression

1. Introduction

把模型用在資源有限的環境下，擁有比較少量的參數，但是與原模型有差不多的效能

五個 network compression 技術（軟體導向）：

1. Network Pruning
2. Knowledge Distillation
3. Parameter Quantization
4. Architecture Design
5. Dynamic Computation

五種技術的前四種不互斥，可以同時使用

2. Network Pruning

network 中有許多參數，有可能有些參數沒有用處，只是佔空間、浪費運算資源而已，而 **network pruning 就是把 network 中沒有用的參數找出來刪除掉**

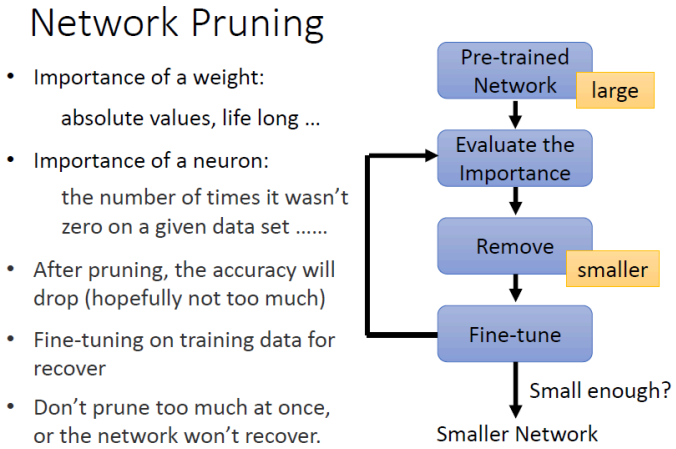

1. 訓練一個大的模型

2. **評估 weight 或 neuron 的重要性**
    - **weight** 的重要性
        - 參數加上絕對值得大小
        - 套用 LLL 的思想，計算 b_i
    - **neuron** 的重要性
        - 計算神經元輸出不為 0 的次數
3. 移除不重要的 **weight** 或 **neuron**（此時模型性能可能下降）
4. 微調模型
5. 重複步驟 2. 至 4.

2.1 Weight pruning

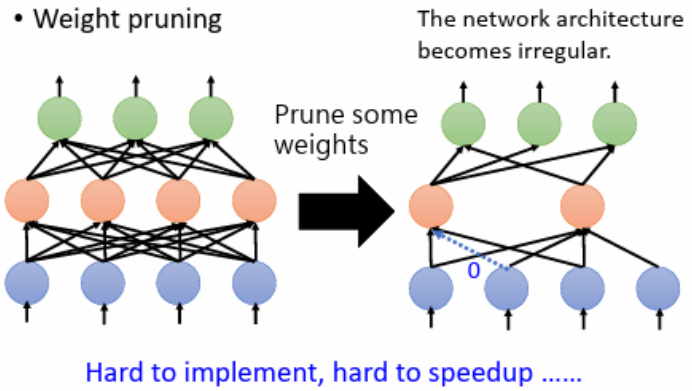

問題：

刪除 weight 後，神經網路形狀不規則，實作上難以實現，也難以使用 GPU 加速矩陣乘法

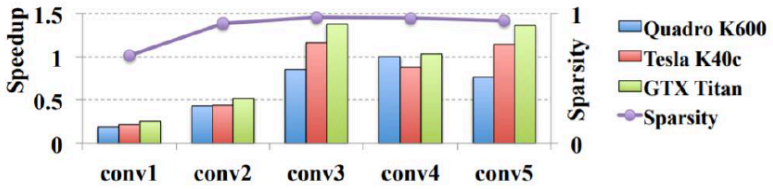

https://arxiv.org/pdf/1608.03665.pdf

以上實驗結果顯示，即使剪掉 95% 的 weight，但是運算時大多時候並沒有變得更快

2.2 Neuron pruning

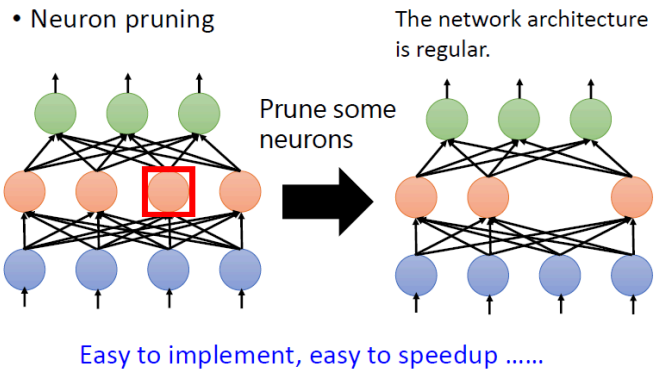

容易實現，且容易加速運算

2.3 Why Pruning ?

問題：

先訓練大的 network 再把它變小，且希望小的 network 跟大的 network 正確率沒有差太多，那麼為什麼不直接訓練小的 network

原因：

因為大的 network 比較好訓練，可參照過去錄影：https://youtu.be/_VuWvQUMQVk

2.3.1 Lottery Ticket Hypothesis

Lottery Ticket Hypothesis 解釋為什麼大的 network 比較容易訓練（注意是"假說"）

大的 network 可以視為是很多小的 sub-network 的組合，當訓練大的 network 時，等於是在訓練很多小的 network

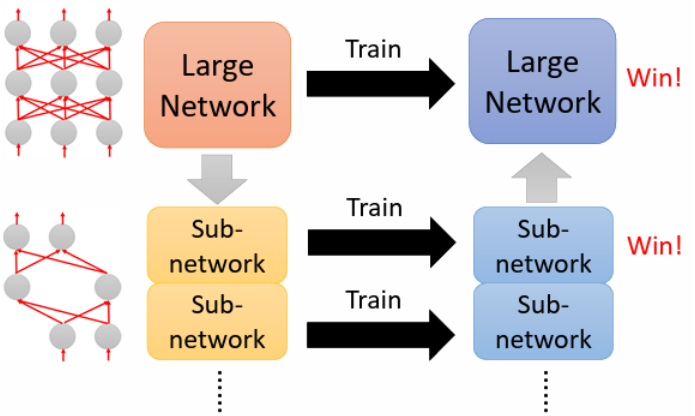

對於每個 sub-network 不一定可以訓練成功，不一定可以透過 gradient descent 找到好的解使 loss 變低。但只要有**大量的 sub-network，其中一個成功，大的 network 就成功了**

實驗證明：

將一參數是隨機初始化的大 network 訓練後進行 pruning 的到一個 pruned network

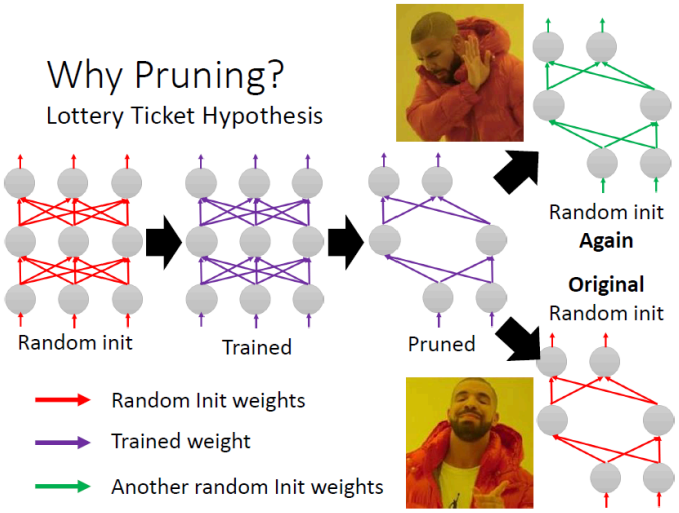

針對此 pruned network 分別採取兩個行為：

- **參數隨機初始化進行訓練**，實驗結果發現**難以訓練成功**
- **參數使用 pruning 前且訓練前 network**，實驗結果發現**可以訓練成功**

解構 Lottery Ticket Hypothesis：

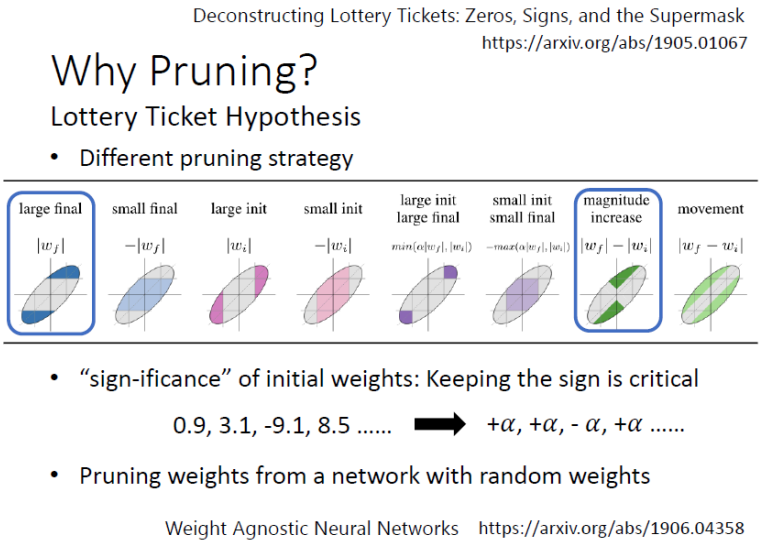

結論：

- 找到了兩種最為有效的 pruning strategy
- **正負號**是 network 能不能被訓練起來的關鍵，絕對值事實上相對不重要
- 隨機初始化 network，就已經可以對一些參數進行剪枝，並得到一個效果不錯的 network

2.3.2 反對大樂透假說：Rethinking the Value of Network Pruning

Dataset	Model	Unpruned	Pruned Model	Fine-tuned	Scratch-E	Scratch-B
CIFAR-10	VGG-16	93.63 (±0.16)	VGG-16-A	93.41 (±0.12)	93.62 (±0.11)	**93.78** (±0.15)
	ResNet-56	93.14 (±0.12)	ResNet-56-A	92.97 (±0.17)	92.96 (±0.26)	**93.09** (±0.14)
			ResNet-56-B	92.67 (±0.14)	92.54 (±0.19)	**93.05** (±0.18)
	ResNet-110	93.14 (±0.24)	ResNet-110-A	93.14 (±0.16)	**93.25** (±0.29)	93.22 (±0.22)
			ResNet-110-B	92.69 (±0.09)	92.89 (±0.43)	**93.60** (±0.25)
ImageNet	ResNet-34	73.31	ResNet-34-A	72.56	72.77	**73.03**
			ResNet-34-B	72.29	72.55	**72.91**

- **New** random initialization, not **original** random initialization in "Lottery Ticket Hypothesis"
- Limitation of "Lottery Ticket Hypothesis" (small lr, unstructured)

- 對於 pruned 後的 network，作完全隨機的初始化，並經過更多 epoch 的訓練，也更得到比 pruned 後的 network 甚至 pruned 前的 network 更好的性能
- 大樂透假說可能只在某些條件下才觀察得到
  - 小的 learning rate
  - 不規則的 network （刪除 weight）

3. Knowledge Distillation

對於同一個任務，訓練兩個 network：

- **Teacher Network**：大的 network，也可以是多個模型的 ensemble
- **Student Network**：小的 network，是真正想要訓練的 network

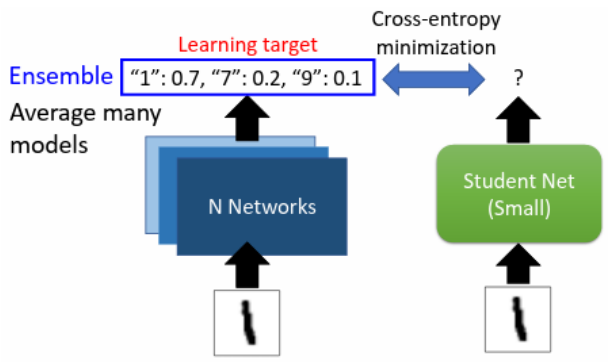

以手寫辨識為例，teacher network 輸出數字的機率分布，student network 的輸出也要是數字的機率分布，**期望與 teacher network 的結果越接近越好**

3.1 Temperature for softmax

輸出是經過 softmax 運算的結果，使每一個數字變為機率分布介於 0 和 1 之間

$$y_i' = \frac{exp(y_i)}{\sum_j exp(y_j)} \xrightarrow{T = 100} y_i' = \frac{exp(y_i/T)}{\sum_j exp(y_j/T)}$$

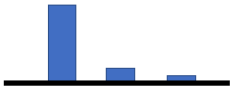

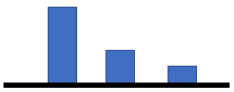

$y_1 = 100 \quad y_1' = 1$

$y_2 = 10 \quad y_2' \approx 0$

$y_3 = 1 \quad y_3' \approx 0$

$y_1/T = 1 \quad y_1' = 0.56$

$y_2/T = 0.1 \quad y_2' = 0.23$

$y_3/T = 0.01 \quad y_3' = 0.21$

問題：

使用原始的 softmax 可能會有機率分布集中的問題，這樣與直接給予正確答案沒有什麼不同，對於 student network 來說沒有幫助，因為 teacher network 沒有提供額外的訊息

解決：

新增超參數 temperature T，使輸出的機率分布變得比較平滑

4. Parameter Quantization

4.1 減少 bits 數

使用較少的空間（bits）儲存一個參數。一般在存一個參數可能是用 64 bits，但可能不必用這麼高的精度，可能用 16 bits、8 bits 或更少就足夠了

4.2 Weight clustering

依參數數值接近程度**將參數分群**，讓**同一群的參數有一樣的數值（取同群參數的平均）**，並**建立一個 table 記錄每一群的值**

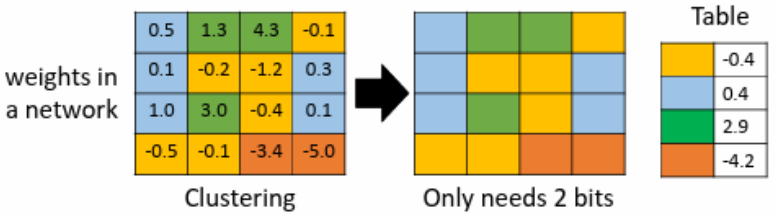

4.3 Huffman encoding

較常出現的使用較少 bits；較少出現的使用較多 bits

4.4 Binary weight

只以正負 1 表示所有參數

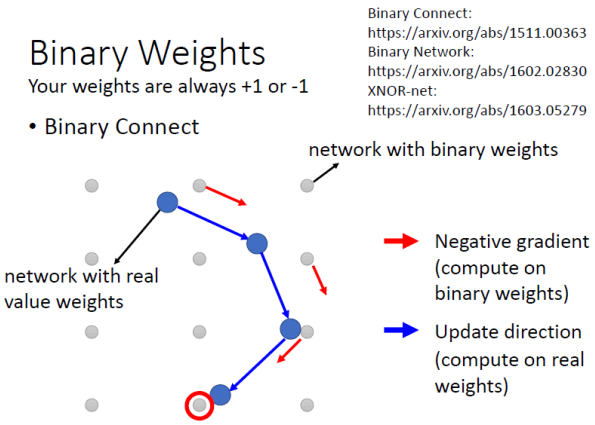

5. Architecture Design

5.1 Low rank approximation

輸入有 N 個 neuron，輸出有 M 個 neuron，兩層之間的參數量 W = N x M ，只要 N 跟 M 其中一者很大，W 的參數量就會很大

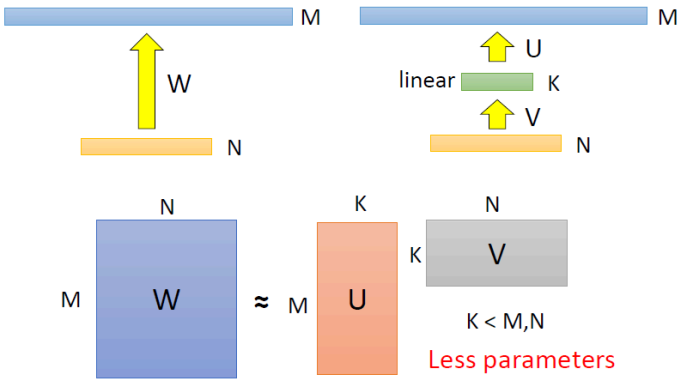

為了減少參數量，可在 N 跟 M 中間新增一層 layer，這一層的 neuron 數目是 K

原參數量是 M x N；而新增一 neuron 數為 K 的 layer 後，**參數量減少為 K x（N + M）**，若 K 遠小於 M 跟 N，那麼 U 跟 V 的參數量加起來，會比 W 還少的多

問題：

W 分成用 U 跟 V 兩層來分開表示時，會減少 W 的可能性，W 的 rank 會 ≤ K

5.2 Depthwise Separable Convolution

5.2.1 Depthwise Convolution

考慮一個 channel 的內部關係

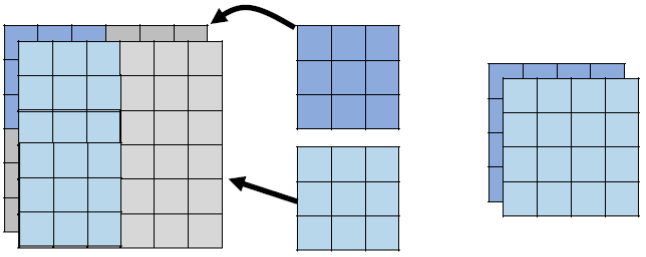

- Filter number = Input channel number
- Each filter only considers one channel.
- The filters are $k \times k$ matrices
- There is no interaction between channels.

- 每個 filter 負責一個 channel
- channel 數目和 filter 數目相同
- input channel 和 output channel 數目相同
- channels 之間沒有互動

5.2.2 Pointwise Convolution

考慮 channels 之間的關係

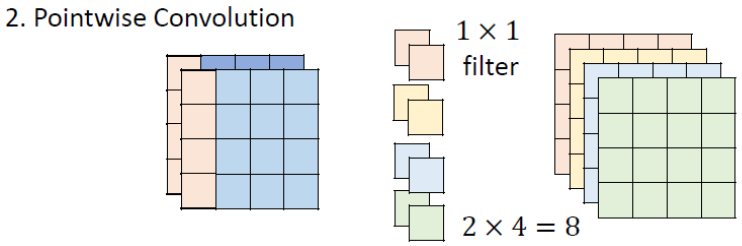

做完 depthwise convolution 後，進行 pointwise convolution

- filter size 限制為 1×1
- 輸入 channel 和輸出 channel 的數目可以不同

二者關係：

觀察右側紅色左上角框內數據的來源，都是來自左側原圖中左上 $3 \times 3 \times 2$ 的區域，只是在depthwise separable convolution中，將原來的一次卷積的操作改為兩次卷積，以此減少參數量

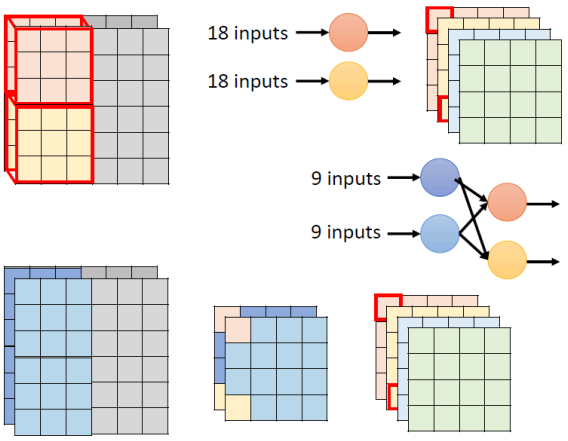

參數量變化：

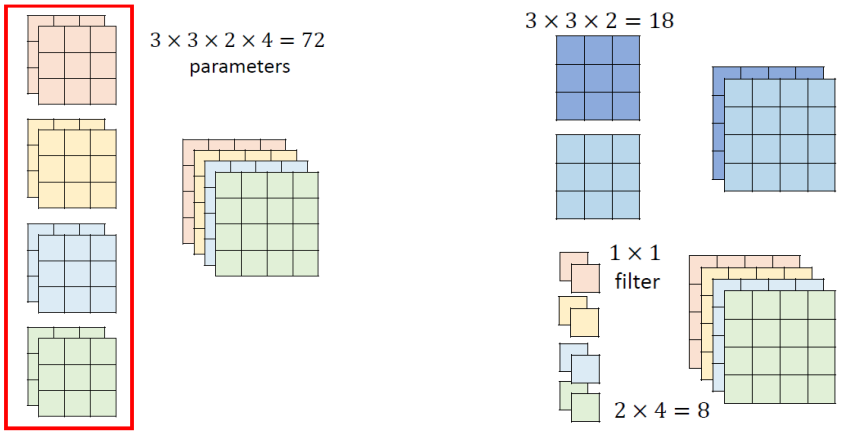

實例：

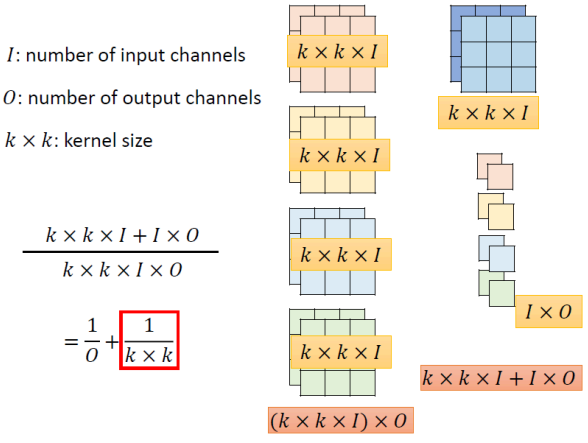

左側為一般的卷積需要的參數量；右邊是 depthwise separable convolution 需要的參數量計算可得，兩者的參數量之比主要取決於 $\frac{1}{k \times k}$

5.3 To learn More

- SqueezeNet
- MobileNet
- ShuffleNet
- Xception
- GhostNet

6. Dynamic Computation

希望 network 可以根據實際運算資源情況，自動調整需要的運算量

6.1 Dynamic Depth

在 layers 間**加上 extra layers**，extra layers 根據每一個 hidden layers 的輸出，**中途決定分類的結果**

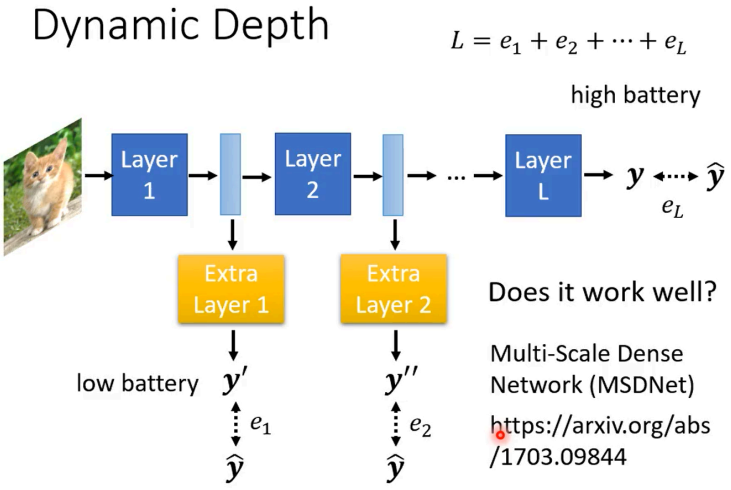

- **運算資源充足**時，可讓圖片**跑過所有的 layer**，得到最終的分類結果

- **運算資源不足**時，讓 network 決定要在哪一個 layer 自行做輸出

期望 ground truth 跟每一個 extra layer 的輸出越接近越好，因此把所有的輸出跟 ground truth 的 cross entropy 加總得到 L，目標最小化 L

其他方法可參考論文：*Multi-Scale Dense Networks for Resource Efficient Image Classification*（**MSDNet**）

6.2 Dynamic Width

在同一個 network 中，設定好幾個不同的寬度

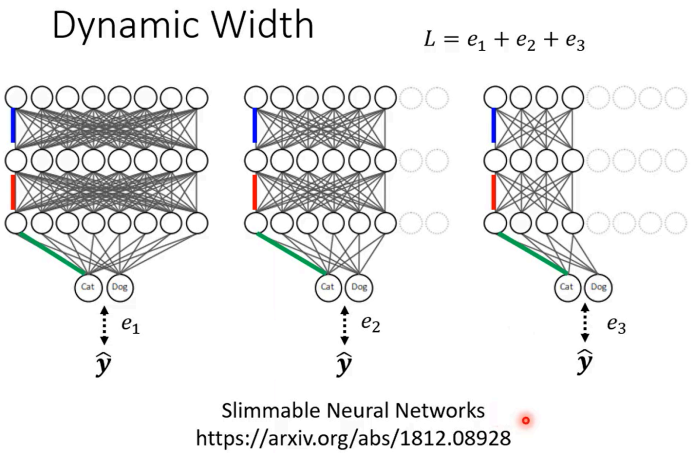

將不同寬度的 network 產生的每一個輸出跟 ground truth 的差距加總得到 L，目標最小化 L

6.3 network 自行決定深度和寬度

根據**輸入資料的難易程度**，讓 network 自行決定執行的寬度和深度

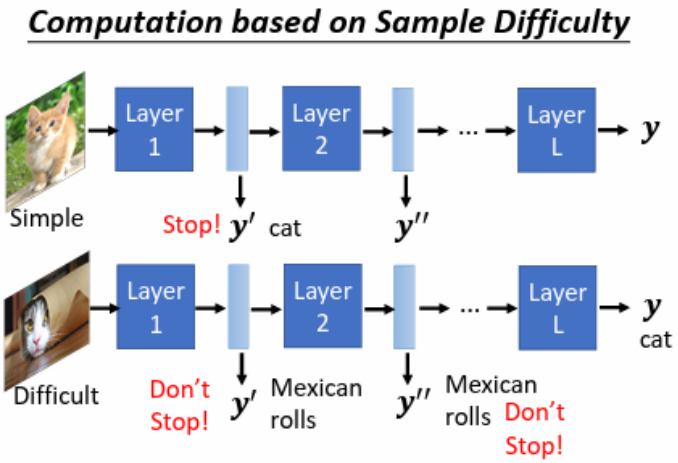

實現：

- SkipNet: Learning Dynamic Routing in Convolutional Networks
- Runtime Neural Pruning

- BlockDrop: Dynamic Inference Paths in Residual Networks